

DESCRIÇÃO DOS RELATÓRIOS A SEREM CRIADOS NO SISTEMA

Visão Geral

Este documento tem por finalidade descrever os primeiros passos e a base teórica dos relatórios e gráficos que serão gerados na aba de estatísticas do *Middleware* de Feature Store. O foco é detalhar o monitoramento de acessos, o ranqueamento de arquivos e a análise de linhagem de dados, garantindo a exploração de variados operadores e funções avançadas da linguagem SQL exigidos no escopo do projeto.

Definição dos Relatórios

A partir do documento de descrição geral do sistema e do fluxo de funcionalidades serão listados os seguintes relatórios analíticos:

- **Análise de Acessos e Downloads:**
 - Com os dados de acessos e downloads será construído um gráfico de barras representando uma linha do tempo em que cada período de tempo (dias, semanas ou meses) terá duas barras, uma de acessos e outra de downloads.
 - Isso resultará em uma análise do crescimento do sistema e a taxa de conversão.
- **Ranking de Datasets Mais Baixados:**
 - A partir dos logs de download descritos na descrição do sistema e no fluxo de funcionalidades, será construído um gráfico que ilustra os “*datasets*” mais baixados no sistema.
 - Para ilustrar usaremos um gráfico de barras listando os top n* “*datasets*” mais baixados.
- **Datasets com Mais Versões:**
 - Criação de uma tabela que elenca datasets que tem maior profundidade de nós, ou seja, que possui a maior quantidade de versões. Nela também conterá o nome do autor, nome do dataset e a quantidade total de “versões filhas” geradas a partir dele.
- **Datasets Menos Visitados:**
 - Cria uma lista com os datasets que potencialmente podem ser excluídos ou arquivados devido a baixa frequência de acessos e/ou downloads

Especificação SQL

Aqui é detalhado as funções SQL utilizadas para cada tipo de relatório:

- **Análise de Acessos por Dataset:**
 - SELECT dos datasets baseado com a data do “*data_log*”;
 - Uso do EXTRACT() para pegar a data em específico
 - GROUP BY agrupa os “*datasets*” baseados nessa relação.
 - Uso do LEFT JOIN() com a tabela dos “*datasets*” sendo a da “esquerda”. Isso possibilitará com que mesmo datasets que não tiveram nenhuma interação sejam avaliados.
- **Ranking de Datasets por Download:**

- SELECT com o uso de INNER JOIN para buscar os datasets relacionados com os logs de download;
- GROUP BY e COUNT() para agrupar e contabilizar os downloads de cada dataset.
- INNER JOIN para pegarmos apenas os datasets que tiverem correspondência com a tabela “*downloads_log*”
- ORDER BY count DESC conjuntamente com limit “*n*”^{*} a fim de trazer o ranking dos “*n*”^{*} datasets já ordenados.
- Datasets com Mais Versões:
 - Necessário juntar a tabela do dataset com ela mesma para conseguir buscar as versões filhas (ex. “*v1.id-versao-base = v2.id-versao*”; ambas são da mesma tabela);
 - O SELECT será usado a partir dessa junção da mesma tabela.
 - Poderá ser usado o count para verificar a quantidade de versões filhas e, há a possibilidade de limitar para que apenas datasets com no mínimo “*m*”^{*} versões filhas sejam mostradas.
- Datasets Menos Visitados:
 - No SELECT usaremos o WHERE para verificar datasets com o último download sendo anterior a uma data limite (exemplos: antes de 6 meses)

* O “*n*” se refere a quantidade de datasets que serão mostrados no ranking. O valor ainda deve ser definido.

* O “*m*” se refere à quantidade mínima de versões filhas que um dataset precisa ter para ser mostrada.